Adaptation de domaine et bornes théoriques

Jean Constantin GEORGES

Université d'Angers

19 Juin 2026

Motivation

En apprentissage supervisé classique, on suppose que :

$$D_{\text{train}} = D_{\text{test}}$$

En pratique, cette hypothèse est souvent fausse :

- images synthétiques vs images réelles ;
- données médicales provenant d'hôpitaux différents ;
- reconnaissance vocale avec accents différents.

Question :
Peut-on transférer un modèle appris sur un domaine source vers un domaine cible différent ?

Cadre de l'adaptation de domaine

Définition d'un domaine

Un domaine est défini par une paire :

$$\langle D, f \rangle$$

où :

- D est une distribution de probabilité sur l'espace d'entrée X ;
- $f : X \to [0, 1]$ est une fonction d'étiquetage.

Dans ce travail :

$$f(x) = \mathbb{P}(Y = 1 \mid X = x)$$

avec $Y \in \{0, 1\}$.

Nous considérons deux domaines :

$$\langle D_S, f_S \rangle \qquad \text{et} \qquad \langle D_T, f_T \rangle$$

Hypothèses et erreurs

Hypothèse de classification

Une hypothèse est une fonction : $h : X \to \{0, 1\}$
qui prédit une classe à partir d'une donnée d'entrée x.

Erreur sur le domaine source

$$\varepsilon_S(h, f_S) = \mathbb{E}_{x \sim D_S} [|h(x) - f_S(x)|]$$

Lorsque la fonction d'étiquetage est implicite : $\varepsilon_S(h) = \varepsilon_S(h, f_S)$

Erreur sur le domaine cible : $\varepsilon_T(h) = \varepsilon_T(h, f_T)$

Objectif

Trouver une hypothèse h minimisant l'erreur cible tout en utilisant principalement des données du domaine source.

Rôle de la divergence entre distributions

Comparer les domaines source et cible

Une mesure naturelle de différence entre distributions est la distance de variation totale :

$$d_1(D, D') = 2 \sup_{B \in \mathcal{B}} \left| \Pr_D(B) - \Pr_{D'}(B) \right|$$

où $\mathcal{B}$ désigne l'ensemble des parties mesurables.

Interprétation

- d_1 mesure la différence maximale entre deux distributions ;
- si d_1 est grand, les domaines sont très différents ;
- si d_1 est petit, les domaines sont proches.

La H-divergence

La H-divergence mesure la capacité d'une classe d'hypothèses à distinguer deux distributions.

Définition
Soit H une classe d'hypothèses sur X.
Pour toute hypothèse $h \in H$, on définit :

$$I(h) = \{x \in X \mid h(x) = 1\}$$

La H-divergence entre D et D' est :

$$d_H(D, D') = 2 \sup_{h \in H} \left| \Pr_D(I(h)) - \Pr_{D'}(I(h)) \right|$$

Interprétation : Même interpretation avec d_1

On peut affirmer que :

$$d_H(D, D') \leq d_1(D, D')$$

Première borne entre erreur source et erreur cible

Théorème 1 : Liaison entre erreurs source et cible

Pour toute hypothèse $h \in H$:

$$\varepsilon_T(h) \leq \varepsilon_S(h) + d_1(D_S, D_T) + \min\left\{\mathbb{E}_{D_S}[|f_S(x) - f_T(x)|], \mathbb{E}_{D_T}[|f_S(x) - f_T(x)|]\right.$$

Interprétation

- $|f_S - f_T|$: mesure si les deux domaines sont d'accord sur son étiquette

Conséquence

Une faible erreur source ne suffit pas : les distributions et les fonctions d'étiquetage doivent aussi être proches.

Idée de la preuve du Théorème 1

On part de : $\varepsilon_T(h) = \varepsilon_T(h, f_T)$
et on ajoute puis soustrait des termes intermédiaires :

$$\varepsilon_S(h, f_S) \qquad \text{et} \qquad \varepsilon_S(h, f_T)$$

Après réorganisation :

$$\varepsilon_T(h) \leq \varepsilon_S(h) + |\varepsilon_S(h, f_T) - \varepsilon_S(h, f_S)| + |\varepsilon_T(h, f_T) - \varepsilon_S(h, f_T)|$$

Contrôle des deux termes

$$|\varepsilon_S(h, f_T) - \varepsilon_S(h, f_S)| \leq \mathbb{E}_{D_S}[|f_S(x) - f_T(x)|]$$

$$|\varepsilon_T(h, f_T) - \varepsilon_S(h, f_T)| \leq d_1(D_S, D_T)$$

On obtient finalement la borne du théorème.

Estimation empirique de la H-divergence

Lemme 4.1

Soit $\mathcal{H}$ une classe d'hypothèses définie sur X, de dimension VC d.
Soient U et U' deux échantillons de taille m, tirés respectivement selon les distributions D et D'.
Soit $\hat{d}_{\mathcal{H}}(U, U')$ la H-divergence empirique calculée à partir de ces échantillons.

Alors, avec probabilité au moins $1 - \delta$:

$$d_H(D, D') \leq \hat{d}_H(U, U') + 4\sqrt{\frac{d \log(2m) + \log\left(\frac{2}{\delta}\right)}{m}}$$

Interprétation

- la H-divergence peut être estimée à partir d'échantillons finis ;
- plus m augmente, plus l'estimation empirique devient précise.

Lemme 4.2 : interprétation de la H-divergence

Lemme 4.2

Soit H une classe d'hypothèses symétrique.
Alors :

$$\hat{d}_H(U, U') = 2\left(1 - \min_{h \in H}\left[\frac{1}{m}\sum_{x:h(x)=0} \mathbf{1}_{x \in U} + \frac{1}{m}\sum_{x:h(x)=1} \mathbf{1}_{x \in U'}\right]\right)$$

Interprétation

- les données source reçoivent le label 0 ;
- les données cible reçoivent le label 1 ;
- on cherche l'hypothèse séparant le mieux les deux domaines.

La H-divergence mesure donc la capacité d'un classificateur à distinguer les distributions source et cible.

Hypothèse idéale et espace $H\Delta H$

Hypothèse jointe idéale

$$h^* = \arg\min_{h \in H} \left(\varepsilon_S(h) + \varepsilon_T(h)\right)$$

On définit : $\lambda = \varepsilon_S(h^*) + \varepsilon_T(h^*)$

Interprétation de λ

- si λ est faible : une hypothèse performante existe sur les deux domaines ;
- si λ est grand : l'adaptation devient difficile voire impossible.

Espace de différence symétrique

$$g \in H\Delta H \iff g(x) = h(x) \oplus h'(x)$$

avec $h, h' \in H$ et $\oplus$ désigne l'opérateur XOR.

L'espace $H\Delta H$ permet de définir une divergence plus fine entre distributions appelée $H\Delta H$-divergence.

Lemme 4.3 — Contrôle de la différence d'erreur

Lemme 4.3. Pour toutes hypothèses $h, h' \in \mathcal{H}$:

$$\left|\varepsilon_S(h, h') - \varepsilon_T(h, h')\right| \leq \frac{1}{2} d_{\mathcal{H}\Delta\mathcal{H}}(D_S, D_T).$$

Avec :

$$d_{\mathcal{H}\Delta\mathcal{H}}(D_S, D_T) = 2 \sup_{h,h' \in \mathcal{H}} \left| \Pr_{x \sim D_S}\left[h(x) \neq h'(x)\right] - \Pr_{x \sim D_T}\left[h(x) \neq h'(x)\right] \right|.$$

Interprétation :

- Le lemme compare le désaccord entre deux hypothèses sur les domaines source et cible.
- Si la divergence $d_{\mathcal{H}\Delta\mathcal{H}}(D_S, D_T)$ est faible : $\varepsilon_S(h, h') \approx \varepsilon_T(h, h')$
- Donc les comportements des hypothèses restent similaires sur les deux domaines.

Idée clé : $\mathcal{H}\Delta\mathcal{H}$ mesure uniquement les régions où les hypothèses de $\mathcal{H}$ se contredisent.

Théorème 2 — Borne fondamentale

Théorème 2. Soit $\mathcal{H}$ une classe d'hypothèses de dimension VC d.

Pour toute hypothèse $h \in \mathcal{H}$, avec probabilité au moins $1 - \delta$:

$$\varepsilon_T(h) \leq \varepsilon_S(h) + \frac{1}{2}\hat{d}_{\mathcal{H}\Delta\mathcal{H}}(U_S, U_T) + 4\sqrt{\frac{2d\log(2m') + \log\left(\frac{2}{\delta}\right)}{m'}} + \lambda.$$

Idée générale :
La performance sur le domaine cible dépend :

- de la performance sur le domaine source ;
- de la différence entre les distributions ;
- de l'existence d'une bonne hypothèse commune.

Ce résultat identifie précisément les conditions nécessaires à une adaptation de domaine réussie.

Preuve du Théorème 2

La preuve repose sur le Lemme 3 ainsi que sur l'inégalité triangulaire pour l'erreur de classification :

$$\varepsilon(f_1, f_2) \leq \varepsilon(f_1, f_3) + \varepsilon(f_3, f_2).$$

On a : $\varepsilon_T(h) \leq \varepsilon_T(h^*) + \varepsilon_T(h, h^*)$.
avec : $\varepsilon_T(h, h^*) = \varepsilon_S(h, h^*) + (\varepsilon_T(h, h^*) - \varepsilon_S(h, h^*))$.
Ainsi :

$$\varepsilon_T(h) \leq \varepsilon_T(h^*) + \varepsilon_S(h, h^*) + |\varepsilon_T(h, h^*) - \varepsilon_S(h, h^*)|.$$

Donc, en appliquant les lemmes 3 et 1, l'inégalité triangulaire on obtient le résultat final.

Exemple synthétique : structure d'un domaine

Afin d'illustrer les résultats théoriques de l'adaptation de domaine, nous construisons deux domaines synthétiques :

$$\mathcal{D}_S = (D_S, f_S), \qquad \mathcal{D}_T = (D_T, f_T).$$

Pour chaque observation $x \in \mathcal{X}$, nous distinguons trois objets :

1. un **score réel**
$$s(x) \in \mathbb{R};$$
2. une **probabilité d'étiquetage**
$$g(x) = \mathbb{P}(Y = 1 \mid X = x);$$
3. une **fonction d'étiquetage déterministe**
$$f(x) \in \{0, 1\}.$$

Cette distinction permet de modéliser explicitement le bruit d'étiquetage et de séparer la règle théorique des labels observés.

Génération des labels et bruit d'étiquetage

Le score $s(x)$ est transformé en probabilité grâce à la fonction sigmoïde :

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

La probabilité d'étiquetage est définie par :

$$g(x) = \mathbb{P}(Y = 1 \mid X = x) = \sigma\left(\frac{s(x)}{\tau}\right),$$

où le paramètre $\tau > 0$ contrôle le niveau de bruit :

- τ petit : labels presque déterministes ;
- τ grand : labels plus bruités.

La fonction d'étiquetage théorique est alors : $f(x) = \mathbf{1}\left[g(x) \geq \frac{1}{2}\right]$.
Enfin, les labels observés sont générés aléatoirement selon :

$$Y \mid X = x \sim \text{Bernoulli}(g(x)).$$

Définition du domaine source $\mathcal{D}_S = (D_S, f_S)$

Nous construisons un domaine source avec :

$$D_S = \frac{1}{2}\mathcal{N}(\mu_1, \Sigma_1) + \frac{1}{2}\mathcal{N}(\mu_2, \Sigma_2).$$

qui est définie comme un mélange équilibré de deux lois gaussiennes.

- chaque observation provient de l'une des deux composantes gaussiennes ;
- les deux composantes sont choisies avec probabilité $1/2$

Le score latent du domaine source est défini par :

$$s_S(x) = x_1 + 0.8x_2 + 0.5\sin(2x_1).$$

- x_1 et x_2 contribuent linéairement au risque ;
- le terme $\sin(2x_1)$ introduit une non-linéarité.

Définition du domaine cible $\mathcal{D}_T = (D_T, f_T)$

Le domaine cible est obtenu à partir du domaine source par une transformation géométrique : $X_T = X_S A R^\top + b$, où :

$$A = \begin{pmatrix} 1.2 & 0 \\ 0 & 0.8 \end{pmatrix}, \qquad R(\theta) = \begin{pmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{pmatrix},$$

avec $\theta = 0.45, \qquad b = (0.8, -0.4)$.

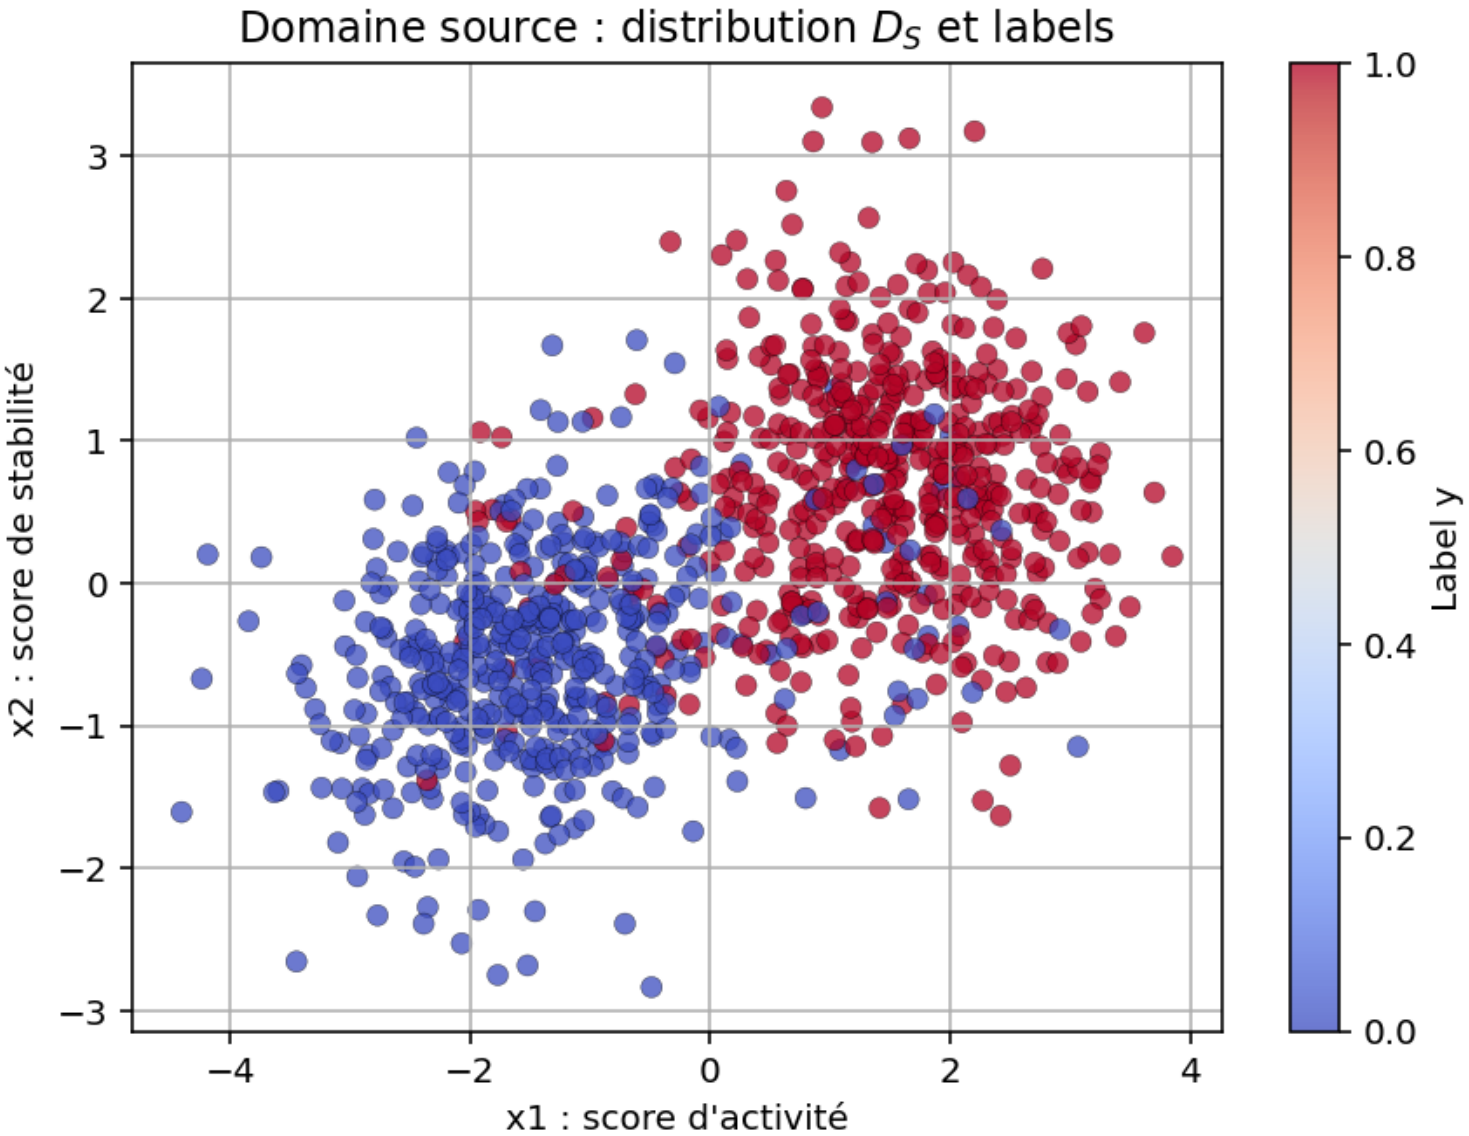
- A étire ou compresse les axes ;
- $R(\theta)$ effectue une rotation du plan ;
- b introduit une translation.

Le score latent du domaine cible est défini par :

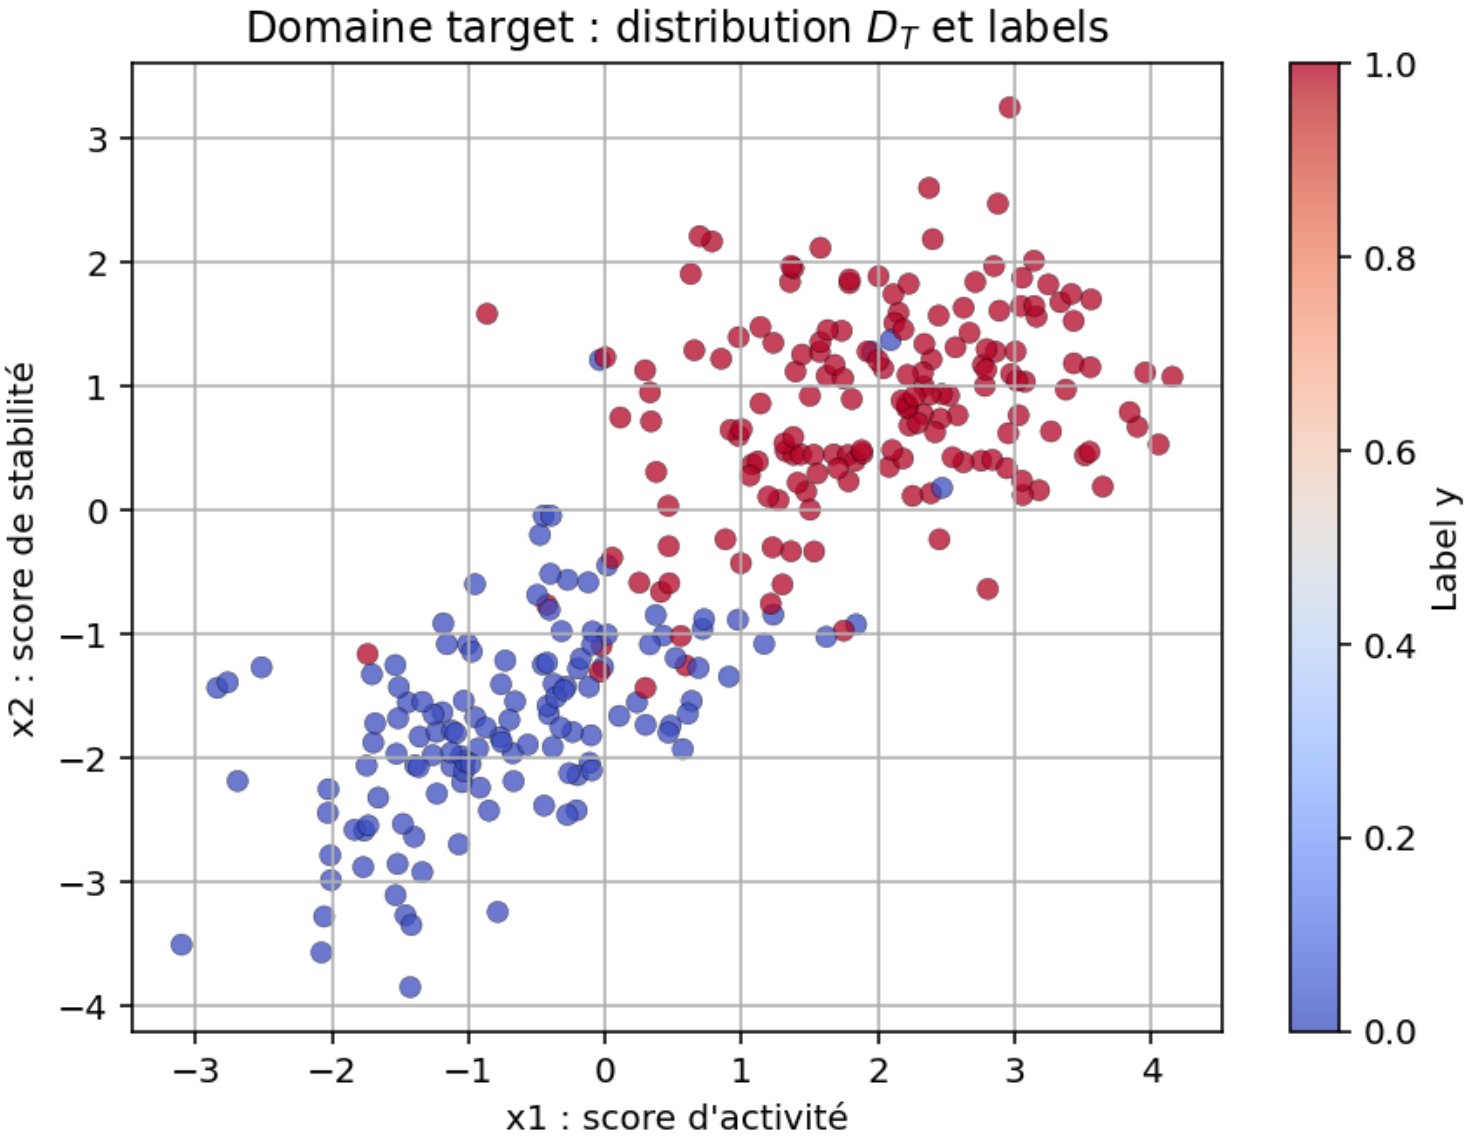
$$s_T(x) = 0.9x_1 + x_2 + 0.5\sin(2x_1 + 0.4).$$

Cette définition modifie légèrement la règle d'étiquetage par rapport au domaine source.

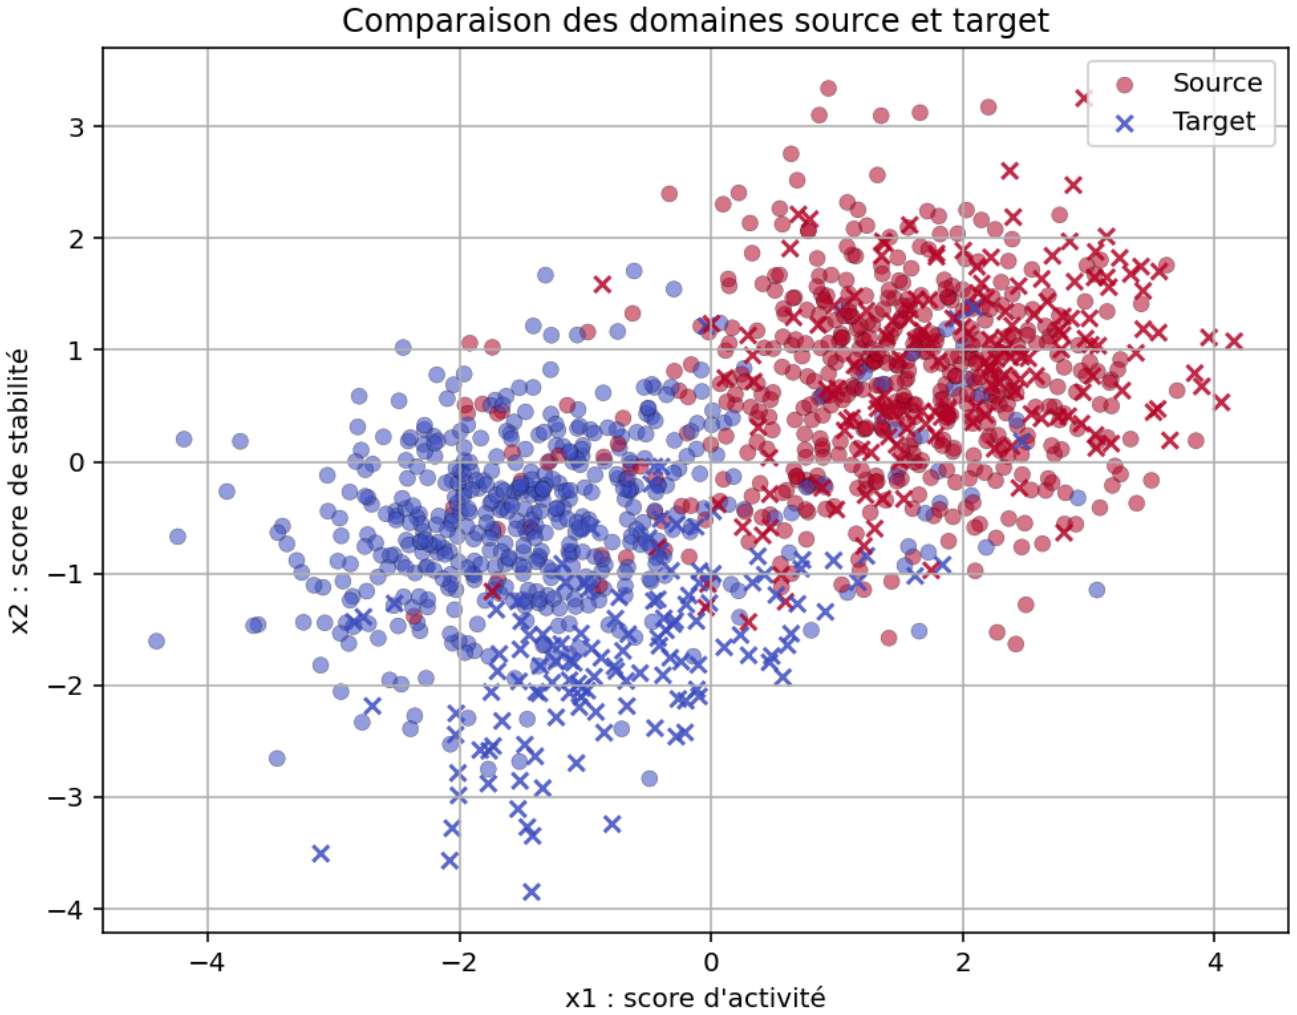
Domaine source $\mathcal{D}_S = (D_S, f_S)$



Domaine cible $\mathcal{D}_T = (D_T, f_T)$



Visualisation du décalage de domaine



$$D_S \neq D_T \quad \Longrightarrow \quad d_{\mathcal{H}\Delta\mathcal{H}}(D_S, D_T) > 0.$$

Interprétation du Théorème 2

$$\varepsilon_T(h) \leq \varepsilon_S(h) + \frac{1}{2} d_{\mathcal{H}\Delta\mathcal{H}}(D_S, D_T) + \lambda.$$

- $\varepsilon_S(h)$: erreur sur le domaine source ;
- $d_{\mathcal{H}\Delta\mathcal{H}}$: divergence entre les distributions ;
- λ : compatibilité des tâches source et cible.

Dans notre exemple :

$\varepsilon_S(h)$ faible, $d_{\mathcal{H}\Delta\mathcal{H}}$ modéré, λ faible.